

MBA706 Term Project — Yu Wang 任务清单

角色：Calendar 数据负责人（5 城市清洗 + 占用率计算 + 合并）

一、任务一句话总结

负责把 5 个城市的 calendar.csv 清洗成统一格式，按城市落地一份 cleaned 文件，再合并出一份多城市表，并基于它计算 occupancy，供 listings/reviews 团队和最终模型/推荐使用。

二、为什么你这块特别关键

课程文档（MBA706_Term_Project.docx, Section 4 Data Cleaning）原文：

“Clean and merge all three files (listings, reviews, calendar) across all five cities. Parse prices, handle missing values, remove outliers, compute occupancy from calendar data. Document your decisions.”

项目核心 Revenue Equation：Annual Revenue = Price × Occupancy × 365。Occupancy 这一项只能从 calendar 数据里算出来——也就是你这份产出。如果这块不到位，后面的投资推荐就立不住。

三、当前数据状况（已替你核过）

每个城市的 calendar.csv 列结构相同：

listing_id, date, available, price, adjusted_price, minimum_nights, maximum_nights

文件大小：

- Hawaii/calendar.csv ≈ 442 MB
- Los Angeles/calendar.csv ≈ 622 MB
- Nashville/calendar.csv ≈ 128 MB
- New York/calendar.csv ≈ 471 MB
- San Francisco/calendar.csv ≈ 102 MB

注意点：

- available 是 t/f 字符串，需要转布尔。
- price / adjusted_price 在样本中常见 NaN，多对应不可订日期。
- 文件大，必须用 chunksize 分块处理（LA 622MB 一次性读会爆内存）。
- 已有模板 scripts/cleaning/calendars/run_full_calendar_cleaning.py 不能直接跑，因为它读 data/raw/calendars/calendar_<city>.csv，你的实际数据在 data/Term Project/<City>/calendar.csv，需要修路径或建立目录映射。

四、你的详细任务清单（建议顺序）

步骤 1：与队友对齐口径（半小时）

- city 列命名规范（建议小写下划线：new_york / los_angeles / san_francisco / nashville / hawaii）。
- listing_id 在三种文件中都保持原始 int64，不被改写。
- 统一日期格式：YYYY-MM-DD。
- 缺失值统一用 NaN，不用空串或 "NA"。

步骤 2：决定 calendar 清洗规则（写下来）

- 去重：同一 (listing_id, date) 只保留一条。
- 必填字段：listing_id、date、available 不能空。
- available：t→True / f→False，其他值视为非法剔除。
- price、adjusted_price：去 \$、,，转 float；available=False 的缺失允许保留为 NaN。
- minimum_nights、maximum_nights：转 Int64；对极端值（如 >1125）做 winsorize 或标记。
- 价格离群值：用 IQR 或分城市的 99 分位裁剪（推荐分城市，因为 Hawaii/SF 与 Nashville 价位差很大）。
- 日期合理性：只保留“今天起 365 天内”的日期。

把上述决策写到 results/calendars/calendar_cleaning_decisions.md，对应课程要求的“documented decisions”。

步骤 3：把现有清洗脚本跑通

复用并修正 scripts/cleaning/calendars/run_full_calendar_cleaning.py：

- 改 RAW_DIR 与匹配模式，使其指向 data/Term Project/*/calendar.csv，并从父目录名提取 city；或在 data/raw/calendars/ 下做 5 份软链/拷贝，命名 calendar_<city>.csv。
- 输出每城市一份：data/processed/calendars/<city>_calendar_cleaned.csv。
- 输出审计：results/calendars/calendars_cleaning_audit.csv（脚本已自带）。

步骤 4：补脚本里目前还没做的两块

- 1 离群值处理：当前脚本没有 outlier 剔除。给 price、minimum_nights 做分位裁剪，并在 audit 中记录被裁剪行数。
- 2 occupancy 计算：在 cleaned 的 per-listing-per-day 之上，再聚合一份 listing 级占用率表。

occupancy 表建议字段：

```
listing_id, city, n_days, n_booked_days,  
occupancy_30d, occupancy_60d, occupancy_90d, occupancy_365d,  
avg_price_when_available, median_price_when_available,  
est_annual_revenue_365 = avg_price_when_available * occupancy_365d * 365
```

建议：n_booked_days = sum(available == False)（Inside Airbnb 惯例：f 视作不可订）。把口径写进 decisions 文档，避免下游算错。

步骤 5：合并 5 城市

- data/processed/calendars/all_cities_calendar_cleaned.csv（很大，建议同时存 .parquet）。
- data/processed/calendars/all_cities_listing_occupancy.csv（这是交付给 Belu 和后面建模/推荐部分的核心成果）。

步骤 6：给团队的一页“数据说明”

放在 results/calendars/calendar_dataset_README.md，写清楚：

- 输入文件清单与每城市最早/最晚日期。
- 你做的清洗规则。
- occupancy 的具体定义（避免下游算错收入）。
- 已知风险（LA 文件大、Hawaii 价格右偏等）。

步骤 7：与 listings/reviews 团队联调

- 跟 Belu 确认 listings 清洗后 listing_id 仍是同类型；做一次 join 测试，listing 命中率应 $\geq 95\%$ ，否则排查。
- 跟 Agostino 对齐 reviews 中 city 列命名一致。

五、交付物清单

代码：

- scripts/cleaning/calendars/run_full_calendar_cleaning.py （修过、能跑通、含 occupancy）

中间数据：

- data/processed/calendars/<city>_calendar_cleaned.csv （5 份）
- data/processed/calendars/<city>_listing_occupancy.csv （5 份）
- data/processed/calendars/all_cities_calendar_cleaned.csv （或 .parquet）
- data/processed/calendars/all_cities_listing_occupancy.csv

审计与文档：

- results/calendars/calendars_cleaning_audit.csv
- results/calendars/calendar_cleaning_decisions.md
- results/calendars/calendar_dataset_README.md

六、避免踩坑（提醒）

- 不要 read_csv 一次性读 LA 那个 622MB 文件，沿用 chunksize=200_000。
- price 缺失不等于价格为 0：available=False 时缺失正常；available=True 时还缺失才需要警告。
- occupancy 只在“看得到的窗口”里算，不要默认乘 365；在 README 中说明窗口长度。
- 团队约定 RANDOM_STATE=42，不要乱设其他随机种子。
- 路径写相对 PROJECT_ROOT，不要写 OneDrive 绝对路径。